
AV1 · ROTEIRO DE VÍDEO

Árvore de Decisão para Campanhas Educativas no Trânsito

Roteiro alinhado à tela do dashboard — cada bloco descreve o que mostrar e o que falar, com números reais já preenchidos (acurácia 41%, recall fatais 75.2%, lift 751.8×).

BASE

72.529 sinistros PRF · 2025

ALGORITMO

DecisionTree · criterion=entropy

Roteiro do Vídeo — AV1

Árvore de Decisão para Campanhas Educativas no Trânsito

Como usar este roteiro. Este roteiro está **alinhado à tela do dashboard** — cada bloco descreve exatamente o que deve aparecer na tela e o que deve ser falado. Os números já estão preenchidos com os valores reais do dashboard (acurácia 41%, recall fatais 75.2%, lift 751.8×, precision 21.2%, recall sem vítimas 56.1%, gap +0.010). Basta seguir a ordem dos blocos, do topo ao rodapé do dashboard.

6 min	7	5-7 min	1080p
Duração alvo	Blocos	Faixa aceita	Resolução

Cronograma geral — do topo ao rodapé do dashboard

Bloco	Tempo	Conteúdo
1	0:00 - 0:30	Abertura — Hero do dashboard
2	0:30 - 1:30	Painel de contexto + 6 KPIs
3	1:30 - 2:30	Anti-vazamento de dados
4	2:30 - 3:30	Matriz de confusão + classification report
5	3:30 - 4:30	Top 20 atributos + árvore de decisão
6	4:30 - 6:00	Recomendações de campanha
7	6:00 - 7:00	Distribuições + hiperparâmetros + encerramento

1

Abertura — contexto e pergunta

0:00 – 0:30

MOSTRAR NA TELA:

Tela do navegador aberta em **<http://localhost:3000/#hero>**, no VS Code. Mostrar o topo do dashboard: ícone vermelho + título "**Campanhas Educativas no Trânsito · Dashboard**" + subtítulo "**Árvore de Decisão (entropy) · 72.528 sinistros PRF**". Menu de navegação com 5 abas: Visão geral, Matriz, Atributos, Campanhas, Método.

"Olá. Este é o dashboard do nosso trabalho de Árvore de Decisão para apoiar campanhas educativas no trânsito. A base é da Polícia Rodoviária Federal — **72.528 sinistros** analisados com critério de entropia, o mesmo ganho de informação do ID3 clássico.

A pergunta gerencial que guiou todo o projeto é: **quais características dos sinistros estão mais associadas à ocorrência de vítimas fatais, e devem ser priorizadas em campanhas preventivas?** Vou percorrer o dashboard do topo até o rodapé, explicando cada decisão."

Dica do roteiro: Fale devagar. A primeira frase define o tom. Mostre o navegador inteiro, não só o dashboard.

2

Painel de contexto e KPIs

0:30 – 1:30

MOSTRAR NA TELA:

Rolar devagar para baixo, mostrando na ordem:

1. O rótulo "**PAINEL DE APOIO À DECISÃO · AV1**"
2. O título "**Campanhas Educativas no Trânsito**"
3. As 3 tags coloridas de classes: **Vermelha "Com Vítimas Fatais"**, **Amarela "Com Vítimas Feridas"**, **Verde "Sem Vítimas"**
4. A primeira linha de 3 KPIs: **Acurácia — Teste: 41.0%** (Baseline 77.5%, delta -0.365 em vermelho) · **Recall — Fatais: 75.2%** (Baseline 0.0%, lift +0.752 em verde) · **Lift Fatais: 751.8x**
5. A segunda linha: **Precisão — Fatais: 21.2%** · **Recall — Sem Vítimas: 56.1%** · **Gap Overfitting: +0.010**

"Aqui no topo vem o painel de contexto. As três tags coloridas representam as classes do nosso alvo: **vermelho para fatais, amarelo para feridos e verde para sem vítimas**. A distribuição é desbalanceada — 77,5% feridos, 15,4% sem vítimas e só 7,2% fatais.

Agora os KPIs. Vejam o primeiro card: **acurácia de teste de 41%**, contra baseline de 77,5%. Parece pior, mas é proposital. O segundo card mostra o porquê: **recall de fatais saltou para 75,2%**, contra **zero do baseline**. Em políticas públicas, encontrar os sinistros fatais vale mais do que acertar o total.

O terceiro card mostra o lift: **751 vezes** mais recall de fatais que o baseline. Os outros três KPIs completam o diagnóstico: precisão de fatais 21,2%, recall de sem vítimas 56,1% e gap de overfitting de apenas 0,010 — sinal de que o modelo generaliza bem."

Dica do roteiro: Aponte o mouse para cada card conforme fala dele. Pare 1 segundo em cada número.

3

Anti-vazamento de dados

1:30 - 2:30

MOSTRAR NA TELA:

Continuar rolar para baixo até a seção "**Anti-vazamento de dados**" (card com ícone de escudo amarelo). Mostrar as 7 colunas listadas como tags: **pessoas, mortos, feridos_leves, feridos_graves, ilesos, ignorados, feridos**. Mostrar também o trecho do código com o `assert not set(LEAKAGE_COLS) & set(X.columns)`.

"Esta é a parte mais crítica de rigor metodológico. As **sete colunas destacadas aqui** — pessoas, mortos, feridos_leves, feridos_graves, ilesos, ignorados e feridos — **são a contagem pós-evento que originou o próprio rótulo**. Se eu as incluísse como preditores, o modelo atingiria quase 100% de acurácia artificial, apenas redescobrimo a regra que gerou o rótulo.

Por isso, no código, há um **assert** explícito que **bloqueia a presença** dessas colunas em X. Se outro profissional tentar adicioná-las no futuro, o pipeline quebra imediatamente. Essa é uma proteção metodológica permanente — nada de fator acionável para campanha pode vir dessas colunas."

Dica do roteiro: Aponte para cada uma das 7 tags enquanto fala "pessoas, mortos, feridos_leves..." — fica visualmente claro.

4

Matriz de confusão e métricas

2:30 - 3:30

MOSTRAR NA TELA:

Rolar até a seção "**Matriz de Confusão (normalizada por classe real)**". Passar o mouse na célula **última linha, primeira coluna** (Fatais reais × Fatais preditos) — tooltip mostra **75.2%**. Depois rolar para a tabela "**Classification Report (teste)**" mostrando precision/recall/F1/suporte por classe.

"Esta é a matriz de confusão. Cada linha é uma classe real, cada coluna é uma classe predita. A diagonal principal mostra os acertos. Olhem a **última linha, classe "Com Vítimas Fatais"**: o modelo acerta **75,2%** dos casos fatais — isso contra **zero do baseline**. Sim, ele erra mais nos sem vítimas, mas em políticas públicas preferimos o falso positivo ao falso negativo.

A tabela ao lado confirma as métricas: para a classe fatais, **precision de 21,2%, recall de 75,2% e F1 de 0,330**. O macro-average cai porque as três classes são tratadas com o mesmo peso, mas o macro recall sobe — sinal de que o modelo aprende a distinguir as três classes, não apenas a majoritária."

Dica do roteiro: Use o cursor para traçar a diagonal da matriz. Pausa de 1 segundo ao citar "75,2%".

5**Atributos mais importantes**

3:30 – 4:30

MOSTRAR NA TELA:

Rolar até a seção "**Top 20 Atributos — feature_importances_**". Passar o mouse sobre as 3 primeiras barras (no topo) para mostrar os tooltips com nome e importância. Cores: **vermelho**=veículos, **laranja**=causa_acidente, **amarelo**=tipo_acidente, **verde**=tipo_pista, **ciano**=tracado_via, **azul**=fase_dia, **roxo**=periodo_dia, **rosa**=condicao_metereologica. Depois rolar para a **preview da Árvore de Decisão** (primeiros 3 níveis).

"Aqui está o coração do trabalho: **os 20 atributos que mais contribuem para reduzir a entropia do alvo**, medidos pelo ganho de informação acumulado em cada split da árvore — não pela frequência bruta.

No topo aparecem os principais, com suas importâncias numéricas ao lado. As cores indicam a coluna original: vermelho para veículos, laranja para causa do acidente, roxo para período do dia, e assim por diante. Logo abaixo temos a **preview da árvore de decisão** — primeiros 3 níveis. As cores mais saturadas indicam nós mais puros, e o caminho da raiz até qualquer folha é uma regra interpretável por humanos."

Dica do roteiro: Aponte para a primeira barra e segure 1 segundo antes de falar "veículos". Clique em "Ampliar" para abrir o modal da árvore full.

6

Recomendações de campanha

4:30 – 6:00

MOSTRAR NA TELA:

Rolar até a seção "**Recomendações de Campanha — Top 10 Atributos**". Mostrar os cards (2 colunas). Em cada card destacar: **nº do rank**, **nome do atributo**, **badge de lift colorido** (vermelho para lift maior que 2×, laranja para maior que 1,5×), **3 mini-stats** (Casos, % Fatais, Importância), e as 4 dimensões: **Tipo, Público, Momento, Canal**.

"Para cada um dos 10 atributos mais importantes, gerei automaticamente um card de recomendação de campanha. Vejam o primeiro: o atributo **veículos alto** aparece em cerca de 36% dos sinistros, e **13,5% desses casos são fatais** — um **lift de 1,87 vezes** acima da taxa global de 7,2%. Isso significa: sinistros com mais veículos envolvidos têm quase o dobro de chance de serem fatais.

Cada card traz quatro dimensões acionáveis: **tipo de campanha** (por exemplo, prevenção de direção embriagada), **público-alvo** (condutores jovens 18-34 em saídas noturnas), **momento** (noite e madrugada, fins de semana) e **canal** (blitz educativas, rádio, redes sociais). Essa ligação direta entre atributo do modelo e ação concreta é o que torna o trabalho acionável para o órgão de trânsito — cada recomendação tem número que a sustenta."

Dica do roteiro: Ao citar lift 1,87×, mostre o badge vermelho no canto superior direito do card. Pausa de 1 segundo.

7

Distribuições e encerramento

6:00 – 7:00

MOSTRAR NA TELA:

Rolar até a seção "**Distribuições da Base de Sinistros**". Clicar em algumas tabs: "**Alvo**" (pie chart 3 classes), "**UF (Top 15)**" (bar horizontal), "**Mês**" (line chart sazonal), "**Causa (Top 15)**". Depois rolar até o rodapé, mostrar o "**Busca de Hiperparâmetros — Grid 3×3**" e voltar ao topo (Hero) para encerrar.

"Por fim, as distribuições da base. Aqui vemos a **distribuição do alvo** em pizza — fica visível o desbalanceamento de 77,5/15,4/7,2%. Na tab **UF**, os estados com mais sinistros. Na tab **Mês**, a sazonalidade — picos em férias e feriados. E na tab **Causa**, as 15 causas mais frequentes.

Abaixo, a **tabela do grid 3×3 de hiperparâmetros** testados: max_depth em 6, 8 e 10, cruzado com min_samples_leaf em 20, 30 e 50. A escolha padrão, em azul, é **max_depth=8 e min_samples_leaf=30** — melhor equilíbrio entre interpretabilidade e generalização.

Em resumo: entregamos um **pipeline reproduzível**, com código versionado, anti-vazamento explícito, baseline de comparação, grid de hiperparâmetros, matriz de confusão interpretável e um **relatório automático de recomendações de campanha**. Tudo está no repositório do GitHub. Obrigado."

Dica do roteiro: Clique em cada tab rapidamente (1 seg cada) só para mostrar que existe. Não precisa explicar todas.

KPIs do dashboard — valores reais

Estes são os números exibidos no dashboard do vídeo. Use esta tabela como referência rápida durante a gravação — cada KPI aparece na seção "Hero" do dashboard, na ordem abaixo.

KPI	Valor	Baseline	Interpretação
Acurácia — Teste	41.0%	77.5%	Aparente retrocesso é proposital (class_weight=balanced)
Recall — Fatais	75.2%	0.0%	GANHO REAL: identifica 75% dos sinistros fatais
Lift Fatais (×)	751.8×	—	Recall de fatais é 751× maior que o baseline trivial
Precisão — Fatais	21.2%	—	De cada 5 alertas de fatal, 1 é verdadeiro
F1 — Fatais	0.330	—	Equilíbrio precision/recall para a classe minoritária
Recall — Sem Vítimas	56.1%	—	Acerta pouco mais da metade dos sem vítimas
Recall — Feridos	34.8%	—	A classe majoritária é sacrificada de propósito
Gap Overfitting	+0.010	—	Modelo generaliza bem (gap < 0.10 é saudável)
Taxa global de fatais	7.18%	—	Taxa base: 7,18% dos sinistros são fatais

Checklist final de gravação

Antes de gravar

- ☐ Dashboard aberto no navegador em **http://localhost:3000/#hero** com zoom 110%
- ☐ VS Code minimizado (não precisa aparecer no vídeo, só o dashboard)
- ☐ Microfone testado (grave 30 seg de teste e ouça)
- ☐ Notificações desligadas (Slack, email, WhatsApp)
- ☐ Ambiente silencioso (sem ar condicionado barulhento, sem gente passando)
- ☐ Roteiro impresso ou em segundo monitor (não ler da mesma tela que grava)
- ☐ Mouse com cursor grande (facilita ver onde está apontando)

Depois de gravar

- ☐ Edição feita (corte respirações longas, "ééé...", "hum...")
- ☐ Legendas geradas (acessibilidade +)
- ☐ Exportação em 1080p MP4, 30fps, bitrate 5-8 Mbps (arquivo final ~150-300 MB)
- ☐ Upload concluído e link testado em janela anônima
- ☐ Link incluído no email final para **lina@ls4business.com.br**

Hospedagem recomendada: YouTube não listado (faça upload, marque como "Não listado", copie o link). Alternativa: Google Drive (compartilhe com "qualquer pessoa com o link"). Não envie o arquivo MP4 por email — é muito grande.