

📺 Roteiro do Vídeo – AV1 Árvore de Decisão

> ****Duração alvo:**** 6 minutos (faixa 5–7 min)
> ****Formato:**** gravação de tela + narração off
> ****Público:**** professora Lina (avaliação acadêmica)
> ****Tom:**** técnico mas acessível, sem jargão desnecessário
>
> ****Como usar este roteiro:****
> - A coluna ****"FALAR"**** tem o texto literal – leia como teleprompter.
> - A coluna ****"MOSTRAR"**** indica o que aparece na tela em cada momento.
> - Os números entre colchetes ``[XX]`` devem ser preenchidos após rodar ``python main.py`` com o CSV real.
> - Cada bloco tem um tempo estimado – ajuste o ritmo para não ultrapassar 7 min.

🕒 Cronograma geral

Bloco	Tempo	Conteúdo
1	0:00 – 0:30	Contexto e pergunta gerencial
2	0:30 – 1:30	Base de dados + vazamento
3	1:30 – 2:30	Engenharia de atributos
4	2:30 – 3:30	Algoritmo e hiperparâmetros
5	3:30 – 5:00	Resultados: baseline x modelo
6	5:00 – 6:30	Atributos importantes e campanhas
7	6:30 – 7:00	Encerramento

📺 BLOCO 1 – Contexto (0:00 – 0:30)

MOSTRAR

Tela cheia do dashboard aberto no Hero (KPIs visíveis no topo)

Ou: logo do curso / slide com o título do trabalho

FALAR

> "Sinistros em rodovias federais brasileiras geram milhares de vítimas todos os anos. Historicamente, as campanhas educativas de trânsito são definidas pela experiência prática dos gestores. O nosso trabalho substitui essa abordagem intuitiva por um modelo ****orientado por dados, auditável e reproduzível****."

>

> "A pergunta gerencial que nos guia é: ****quais características dos sinistros estão mais associadas à ocorrência de vítimas, e devem ser priorizadas como foco de campanhas educativas?**** Para respondê-la, construímos uma Árvore de Decisão treinada com critério de entropia – equivalente ao ID3 clássico."

📺 BLOCO 2 – Base de dados e vazamento (0:30 – 1:30)

MOSTRAR

Abrir o VS Code no arquivo ``main.py``

Rolar até a constante ``LEAKAGE_COLS`` (linha ~74)

Destacar a linha do ``assert not set(LEAKAGE_COLS) & set(X.columns)``

FALAR

> "A base veio da Polícia Rodoviária Federal, via `dados.gov.br`: ****72.529 registros x 30 colunas****, cobrindo os 365 dias de 2025. A leitura exigiu três parâmetros específicos: separador ponto-e-vírgula, encoding latin1 e vírgula decimal – sem eles a acentuação corrompe."

>

> "Mas o ponto mais crítico de rigor metodológico está aqui: ****as sete colunas**** ``pessoas``, ``mortos``, ``feridos_leves``, ``feridos_graves``, ``ilesos``, ``ignorados`` e ``feridos`` ****são a contagem pós-evento que originou o próprio rótulo****. Incluir qualquer uma delas produziria um modelo com aproximadamente 100% de acurácia

artificial – apenas redescobrimo a regra que gerou o rótulo, sem revelar nenhum fator acionável para campanha."

>

> "Por isso, no código, há um `assert` explícito que **bloqueia a presença** dessas colunas em X. Se outro profissional tentar adicioná-las no futuro, o pipeline quebra imediatamente, sinalizando o erro. Essa é uma proteção metodológica permanente."

📁 BLOCO 3 – Engenharia de atributos (1:30 – 2:30)

MOstrar

No VS Code, mostrar a função `aplicar\_engenharia` (linha ~180)

Depois mostrar a função `binarizar\_tracado` (usa MultiLabelBinarizer)

FALAR

> "Três transformações de engenharia foram necessárias antes do treinamento."

>

> "**Primeira:** a coluna `tracado\_via` tinha **605** valores compostos – por exemplo, a string `Reta;Declive` em uma única célula. Não é categórica simples, é **multirrótulo**. Usei o `MultiLabelBinarizer` para decompô-la em colunas binárias, uma por palavra-chave: `tracado\_\_Reta`, `tracado\_\_Curva`, `tracado\_\_Aclive` e assim por diante."

>

> "**Segunda:** `horario`, com 1.412 valores no formato HH:MM:SS, virou `hora\_int` (0 a 23) e `periodo\_dia` em quatro categorias: Madrugada, Manhã, Tarde e Noite. Isso reduz a cardinalidade sem perder a informação sazonal."

>

> "**Terceira:** `data\_inversa`, com 365 datas únicas, virou `mes` (1 a 12) para análise sazonal sem explodir a dimensionalidade."

>

> "Por fim, **causas raras** abaixo de 1% – aquelas com menos de 725 ocorrências – foram agrupadas em `Outros` antes do one-hot encoding. Isso evita que a árvore aprenda regras para categorias com 2 ou 3 amostras, o que geraria overfitting."

📁 BLOCO 4 – Algoritmo e hiperparâmetros (2:30 – 3:30)

MOstrar

Voltar ao dashboard → rolar até a seção "Busca de Hiperparâmetros"

Destacar a linha `max\_depth=8, min\_samples\_leaf=30` em azul

FALAR

> "Usei o `DecisionTreeClassifier` do scikit-learn com `criterion='entropy` – exatamente o critério de impureza baseado em **ganho de informação** pedido no enunciado, equivalente prático ao ID3 e C4.5 clássicos."

>

> "Para os hiperparâmetros, testei um **grid 3 por 3**: `max\_depth` em 6, 8 e 10, cruzado com `min\_samples\_leaf` em 20, 30 e 50. A tabela completa está aqui no dashboard. A escolha padrão foi `max\_depth=8` e `min\_samples\_leaf=30` – melhor equilíbrio entre uma árvore interpretável, que cabe numa página A3 e pode ser mostrada no vídeo, e uma generalização que evita overfitting, com gap entre treino e teste abaixo de 0,10."

>

> "E como as classes do alvo são extremamente desbalanceadas – 77,5% feridos, 15,4% sem vítimas e apenas 7,2% fatais – usei `class\_weight='balanced`". Isso repondera as classes inversamente à sua frequência, forçando o modelo a se importar mais com a classe minoritária. E o `random\_state=42` garante reprodutibilidade total."

BLOCO 5 – Resultados: baseline x modelo (3:30 – 5:00)

MOstrar

Dashboard → rolar até a Matriz de Confusão

Passar o mouse em algumas células para mostrar os tooltips

Depois rolar para o Classification Report

FALAR

> "Primeiro, o **baseline trivial**: um `DummyClassifier` que sempre prevê a classe majoritária – 'Com Vítimas Feridas' – atinge **77,5%** de acurácia sem aprender absolutamente nada. É o piso de comparação. Sem reportar este baseline, qualquer acurácia isolada é enganosa."

>

> "Meu modelo treinado chegou a **[XX]%** de acurácia global no conjunto de teste. À primeira vista, parece **menor** que o baseline. Mas esse aparente retrocesso é deliberado e ético: com `class_weight='balanced'`, o modelo sacrifica a acurácia global para **subir o recall da classe minoritária – os fatais**."

>

> "Olhem a matriz de confusão. A última linha, classe 'Com Vítimas Fatais', mostra que o modelo acerta **[YY]%** dos casos fatais, contra **0%** do baseline. Esse é o ganho real para políticas públicas: identificar sinistros fatais, mesmo errando mais nos sem vítimas."

>

> "O classification report confirma: precision de fatais [ZZ], recall [WW] e F1 [KK]. O macro-average cai porque as três classes são tratadas com o mesmo peso – e a majoritária perde um pouco – mas o macro recall sobe para [AA]%, mostrando que o modelo aprende a distinguir as três classes, não apenas a majoritária."

BLOCO 6 – Atributos importantes e campanhas (5:00 – 6:30)

MOstrar

Dashboard → seção "Top 20 Atributos"

Passar o mouse em algumas barras para mostrar tooltips

Depois rolar para "Recomendações de Campanha"

FALAR

> "Agora, o coração do trabalho: **quais atributos o modelo treinado considera mais importantes** – não pela frequência bruta, mas pelo **ganho de informação acumulado** em cada split da árvore."

>

> "No topo da lista aparecem, em ordem: **[atributo 1]**, com importância [valor]; **[atributo 2]**; **[atributo 3]**; e assim por diante. Cada cor representa a coluna original – laranja para causa do acidente, vermelho para número de veículos, roxo para período do dia, etc."

>

> "Para cada um dos 10 atributos mais importantes, gerei automaticamente um bloco de recomendação de campanha. Vejam, por exemplo, o primeiro: o atributo `[nome real]` aparece em `[n]` casos, ou `[X]%` do total. Desses, **[Y]%** são fatais – um **lift de [Z] vezes** comparado à taxa global de 7,2%. Lift maior que 1 significa que o grupo está super-representado em fatais, e deve ser priorizado."

>

> "Para cada bloco, há quatro dimensões de campanha: **tipo** (por exemplo, prevenção de direção embriagada), **público-alvo** (condutores jovens 18-34 em saídas noturnas), **momento** (noite e madrugada, fins de semana) e **canal** (blitz educativas, rádio, redes sociais). Essa ligação direta entre atributo do

modelo e ação concreta de campanha é o que torna o trabalho acionável para o órgão de trânsito."

BLOCO 7 – Encerramento (6:30 – 7:00)

MOstrar

Vista geral do dashboard rolando de cima embaixo

Voltar ao topo (Hero) e parar

FALAR

> "Em resumo: entregamos um **pipeline reproduzível**, com código versionado, anti-vazamento explícito, baseline de comparação, grid de hiperparâmetros, matriz de confusão interpretável e um **relatório automático de recomendações de campanha** com justificativa numérica."

>

> "O dashboard interativo, os três gráficos em PNG, o relatório em markdown e o código completo estão disponíveis no repositório do GitHub, com README documentando todas as decisões metodológicas."

>

> "A contribuição principal deste trabalho é mostrar que, mesmo com uma técnica clássica como árvore de decisão, é possível – com rigor metodológico adequado – transformar dados públicos de sinistros em **recomendações concretas e auditáveis** para campanhas educativas de trânsito. Obrigado."

Placeholders a preencher antes de gravar

Após rodar `python main.py` com o CSV real, abra `outputs/resultados.json` (ou leia o terminal) e substitua:

Placeholder Significado Onde encontrar

`[XX]` Acurácia teste do modelo KPI "Acurácia – Teste" no dashboard

`[YY]` Recall da classe Fatais Classification Report (linha "Com Vítimas Fatais", coluna recall)

`[ZZ]` Precision Fatais Classification Report

`[WW]` Recall Fatais (mesmo que YY) Classification Report

`[KK]` F1 Fatais Classification Report

`[AA]` Macro avg recall Classification Report (linha "Macro avg")

`[atributo 1]`, `[atributo 2]`, `[atributo 3]` Top 3 features Seção "Top 20 Atributos" no dashboard

`[valor]` Importância do atributo 1 Top 20 Atributos (número ao lado da barra)

`[nome real]`, `[n]`, `[X]`, `[Y]`, `[Z]` Dados do 1º atributo do relatório de campanhas `relatorio\_campanhas.md` (bloco 1)

Dicas práticas de gravação

Antes de gravar

[] Fechar todas as notificações do sistema (Slack, email, WhatsApp)

[] Limpar a área de trabalho / hide desktop icons

[] Aumentar o zoom do VS Code para 125-150% (Command/Ctrl + =) – texto fica legível

[] Aumentar o zoom do navegador para 110% (dashboard)

[] Testar o microfone: gravar 30 seg de teste e ouvir

[] Preparar um copo d'água ao lado

Durante a gravação

Ritmo: falar devagar, mais lento que o normal – parece lento para você, mas fica perfeito para quem assiste

Pausas: a cada 2-3 frases, pausa de 1 segundo – facilita cortes posteriores

Erros: se errar, pare, respire 3 segundos, repita a frase inteira – corte depois

no editor

Cursor: não fique movendo o mouse aleatoriamente enquanto fala – distrai

Depois de gravar

Editor gratuito: DaVinci Resolve (PC/Mac) ou CapCut (mais fácil para iniciante)

Cortes: corte respirações longas, "ééé...", "hum..." – economiza 30-60 segundos

Legendas: se o editor permitir, gere legendas automáticas e corrija – accessibility +

Exportação: 1080p MP4, 30fps, bitrate 5-8 Mbps – arquivo final ~150-300 MB

Hospedagem do vídeo

YouTube não listado (recomendado): faça upload, marque como "Não listado", copie o link

Google Drive: faça upload, compartilhe com "qualquer pessoa com o link"

Vimeo: alternativa mais profissional, plano gratuito limitado a 1 vídeo/semana

Envio

Coloque o link do vídeo no email para `lina@ls4business.com.br`

Não envie o arquivo MP4 por email (muito grande)

Teste o link em uma janela anônima antes de enviar

☒ Checklist final de gravação

[] CSV real da PRF baixado e `python main.py` rodou com sucesso

[] Placeholders do roteiro preenchidos com números reais

[] Dashboard aberto no navegador com zoom 110%

[] VS Code aberto no `main.py` com zoom 125%

[] Microfone testado

[] Notificações desligadas

[] Ambiente silencioso (sem ar condicionado barulhento, sem gente passando)

[] Roteiro impresso ou em segundo monitor (não ler da mesma tela que grava)

[] Gravação feita em 1 take ou 2 takes no máximo

[] Edição feita, legendas geradas

[] Upload concluído e link testado em janela anônima

[] Link incluído no email final para a professora

Bons estudos e boa gravação! 🎥